

Engenharia de Dados – RocketLab 2026.2

Projeto CineData Analytics

Escopo Oficial do Projeto — Pipeline de Dados End-to-End (Databricks | PySpark | SQL)

1. Contexto e Objetivo

Você foi designado(a) como Engenheiro(a) de Dados da **CineData Analytics**, uma empresa de inteligência de mercado do setor audiovisual. Seu trabalho consiste em estruturar os dados de um catálogo de filmes (base combinada TMDb/IMDb) na infraestrutura Data Lakehouse do Databricks.

Você implementará todo o processo de ETL para que os dados brutos — hoje entregues de forma intencionalmente suja e fragmentada em 5 arquivos, na pasta **Inputs** — fiquem prontos para gerar Data Marts analíticos, uma modelagem dimensional (Star Schema) e uma base de contexto para um assistente de Inteligência Artificial, seguindo a **Arquitetura Medalhão (Bronze, Silver e Gold)**.

Além do time de BI, o time de Inteligência Artificial da CineData Analytics também depende da sua entrega: eles estão construindo um assistente virtual baseado em LLM, que precisa de uma tabela específica gerada na sua camada Gold para alimentar um Banco de Dados Vetorial. Essa entrega está detalhada na Seção 4.4.

Seu código e sua organização serão avaliados quanto à funcionalidade, à usabilidade, à aderência aos requisitos estabelecidos neste documento e às boas práticas de desenvolvimento em Engenharia de Dados aprendidos nas aulas.

Parte 1 — Ingestão e Preparação (Camadas Bronze e Silver)

1.1. Preparação e Upload dos Dados

Carregue os 5 arquivos CSV disponibilizados na pasta **Inputs** como Volume no Data Lakehouse do Databricks.

1.2. Notebook — Camada Bronze

Crie um notebook responsável por:

- Criar o banco de dados (database) da camada Bronze.
- Criar as tabelas Bronze a partir de cada CSV, lendo os dados (sem qualquer alteração estrutural ou de conteúdo).
- Adicionar em cada tabela a coluna **ingestion_datetime**, contendo o timestamp exato do momento da inserção do dado na camada Bronze.
- Gravar todas as tabelas em formato Delta, utilizando o modo **Append**.

Mapeamento de Arquivos para Tabelas Bronze:

Arquivo Original	Nome da Tabela (Bronze)
<code>movies_info_IMDB_TMDB.csv</code>	<code>bronze.tb_movies_info</code>
<code>movies_financials_IMDB_TMDB.csv</code>	<code>bronze.tb_movies_financials</code>
<code>movies_metrics_IMDB_TMDB.csv</code>	<code>bronze.tb_movies_metrics</code>
<code>credits_and_tags_IMDB_TMDB.csv</code>	<code>bronze.tb_credits_and_tags</code>
<code>movies_reviews.csv</code>	<code>bronze.tb_movies_reviews</code>

Ingestão de API (obrigatória):

A diretoria financeira quer acompanhar os valores de orçamento e receita dos filmes também em Reais (BRL). Extraia a cotação do dólar via API do Banco Central e salve na tabela `bronze.tb_cotacao_dolar`.

- **Endpoint:**

`https://olinda.bcb.gov.br/olinda/servico/PTAX/versao/v1/odata/CotacaoDolarPeriodo(dataInicial=@dataInicial,dataFinalCotacao=@dataFinalCotacao)?@dataInicial='{data_inicio_formatada}'&@dataFinalCotacao='{data_fim_formatada}'&$select=dataHoraCotacao,cotacaoCompra&$format=json`

- Formato esperado de data: **MM-DD-AAAA**. Use parâmetros (widgets) do notebook para as datas de início e fim.
- Sugestão: consulte os últimos 7 dias corridos a partir da data de execução, já que a API não retorna cotação em finais de semana e feriados.

1.3. Notebook — Camada Silver

Nenhuma alteração será realizada nas tabelas da camada Bronze. Todos os nomes de colunas devem estar em português e a tipagem deve estar correta.

1) `silver.tb_info_filmes` (origem: `tb_movies_info`)

Mapeamento de colunas:

Coluna Origem	Coluna Destino
<code>id</code>	<code>id_filme</code>
<code>title</code>	<code>titulo</code>
<code>original_title</code>	<code>titulo_original</code>
<code>release_date</code>	<code>data_lancamento</code>
<code>runtime</code>	<code>duracao_minutos</code>
<code>original_language</code>	<code>idioma_original</code>
<code>status</code>	<code>status_filme</code>
<code>overview</code>	<code>sinopse</code>

Coluna Origem	Coluna Destino
tagline	frase_divulgacao

- **Limpeza e Tradução do Status:** Antes de traduzir o status_filme (Released → Lançado; Post Production → Pós-Produção; In Production → Em Produção; Planned → Planejado; Rumored → Rumores; Canceled → Cancelado), você deve normalizar a coluna. A coluna de status deve ser normalizada (removendo ruídos, hífens sobressalentes e padronizando a caixa) antes da tradução dos termos para o português. Registros corrompidos ou não mapeáveis devem ser padronizados como "Não Informado"
- **Deduplicação:** A tabela deve conter unicidade por filme. Havendo registros duplicados na origem, mantenha exclusivamente a versão mais recente com base na data de ingestão.
- **Tratamento de Data Multi-Formato:** Converta o campo de data de lançamento testando os diferentes padrões presentes na origem de forma robusta. Apenas valores onde a conversão for estritamente impossível devem ser tratados como ausentes (NULL).
- **Coluna Derivada:** Criar a coluna ano_lancamento, extraída de data_lancamento.

2) silver.tb_financeiro_filmes (origem: tb_movies_financials)

Coluna Origem	Coluna Destino
id	id_filme
budget	orcamento_usd
revenue	receita_usd
orcamento_usd	orcamento_brl
receita_usd	receita_brl

- Tratar valores textuais que representam ausência de dado (ex.: "Unknown", "Não Informado") como NULL antes da conversão de tipo.
- Higienize as colunas de orçamento e receita para remover símbolos de moedas, pontuações de milhar e textos representativos de ausência de dados.
- Converta as métricas para o tipo numérico decimal apropriado e garanta que valores zerados ou negativos sejam tratados como ausentes.
- Calcule os valores equivalentes em Reais (BRL) aplicando a taxa de cotação obtida.
- Derive as colunas de Lucro (Dólar/Real) e Margem de Lucro Percentual, garantindo que operações aritméticas com valores ausentes não invalidem o resultado e evitando divisões por zero.

3) silver.tb_metricas_engajamento (origem: tb_movies_metrics)

Coluna Origem	Coluna Destino
id	id_filme

Coluna Origem	Coluna Destino
popularity	popularidade
vote_average	nota_media_tmdb
vote_count	qtd_votos_tmdb
averageRating	nota_media_imdb
numVotes	qtd_votos_imdb

- A coluna de popularidade apresenta inconsistências de pontuação e separadores decimais na origem. Limpe a formatação numérica da coluna antes da conversão de tipo, garantindo que os valores não sejam invalidados ou convertidos silenciosamente para nulos.
- Devido ao deslocamento de colunas (Column Shift) presente na base bruta, existem textos e atributos fora de contexto espalhados pelas colunas de notas e contagens de votos. Aplique uma conversão de tipagem segura (para valores decimais e inteiros), garantindo que textos ou caracteres incompatíveis sejam tratados como dados ausentes (NULL) sem interromper a execução do pipeline.
- Identifique e trate inconsistências de escala e limites numéricos de negócio: Notas médias (TMDB e IMDb) que estejam fora do intervalo válido de 0 a 10 (incluindo valores multiplicados por erro de escala) devem ser desconsideradas e tratadas como NULL. Contagens de votos ou índices de popularidade com valores negativos devem ser invalidados e tratados como NULL

4) silver.tb_avaliacoes_usuarios (origem: tb_movies_reviews)

Coluna Origem	Coluna Destino
id	id_filme
nome	nome_usuario
nota	nota_usuario
comentario	comentario_usuario

- Remova registros integralmente duplicados (onde a combinação de filme, usuário, nota e comentário seja idêntica), garantindo a unicidade das avaliações.
- Garanta que a nota atribuída pelo usuário respeite a regra de negócio da escala permitida (0 a 10). Qualquer valor fora dessa faixa deve ser descartado e convertido para NULL.
- Identifique comentários não preenchidos ou compostos apenas por espaços em branco e preencha-os de forma explícita com o texto padronizado "Sem comentário".

5) silver.tb_generos (origem: tb_credits_and_tags, coluna genres)

- Explodir (split + explode) a coluna genres, tratando a inconsistência de separadores (vírgula vs. ponto e vírgula) antes do split.

- A origem armazena múltiplos valores delimitados na mesma coluna. Desmembre estes elementos para que cada registro represente um único gênero ou participante/empresa por filme.
- Devido a falhas na estrutura de origem (Column Shift e separadores extras), remova resíduos em branco, textos descritivos e valores numéricos deslocados que não pertençam ao domínio de gêneros ou nomes de entidades.

6) silver.tb_pessoas_empresas (origem: tb_credits_and_tags, colunas cast, directors, writers, production_companies)

Dimensão unificada que consolida quatro tipos de entidade em uma única tabela:

Coluna Origem	tipo_entidade Resultante
cast	'Ator'
directors	'Diretor'
writers	'Roteirista'
production_companies	'Produtora'

- Dimensão unificada que consolida quatro tipos de entidade em uma única tabela (Manter o mapeamento de tipos de entidade: cast -> 'Ator' etc.).
- Padronize a formatação de capitalização de texto, consolide as entidades em um modelo unificado categorizado pelo tipo de atuação (Ator, Diretor, Roteirista, Produtora) e elimine registros duplicados.

7) silver.tb_cotacao_dolar (origem: tb_cotacao_dolar)

- Como a API do Banco Central não possui cotações em finais de semana e feriados, estruture o histórico de forma a garantir uma série temporal contínua.
- Aplique uma técnica de preenchimento (Forward Fill) de modo que dias sem cotação recebam o valor do último dia útil disponível.

Parte 2 — Consagração do Negócio (Camada Gold)

Nesta etapa você construirá os Data Marts consolidados, a modelagem dimensional (Star Schema) para consumo do time de BI, e a tabela de contexto para o time de IA. Utilize exibições de DataFrames em tela (display()) para responder às perguntas de negócio solicitadas. Nenhuma biblioteca de visualização de gráficos é necessária.

Entrega 1 — Modelagem Dimensional (Star Schema)

Construa as seguintes tabelas, utilizando chaves substitutas (Surrogate Keys) geradas via monotonically_increasing_id(), row_number() ou função de hash (sha2):

- **gold.fact_movies_performance**
 - **Grão:** Um registro único por filme.
 - **Objetivo:** Centralizar todas as métricas financeiras e de engajamento do filme.
 - **Chave Estrangeira (FK):** sk_movie_id BIGINT (Apontando para a dim_movies).
 - **Métricas Financeiras (DECIMAL):** orcamento_usd DECIMAL(18,2), receita_usd DECIMAL(18,2), lucro_usd DECIMAL(18,2), orcamento_brl DECIMAL(18,2), receita_brl DECIMAL(18,2), lucro_brl DECIMAL(18,2).
 - **Métricas de Engajamento (DOUBLE/INT):** popularidade DOUBLE, nota_media_tmdb DOUBLE, qtd_votos_tmdb INT, nota_media_imdb DOUBLE, qtd_votos_imdb INT.
 - A tabela fato deve consolidar métricas de filmes lançados sem duplicar grão através dos joins.
- **gold.dim_movies**
 - **Objetivo:** Armazenar os metadados principais e descritivos de cada filme.
 - **Colunas:** sk_movie_id BIGINT (PK), id_filme STRING (Chave natural de origem), titulo STRING, data_lancamento DATE, ano_lancamento INT, duracao_minutos INT, idioma_original STRING, status_filme STRING, sinopse STRING.
- **gold.dim_genres**
 - **Objetivo:** Catálogo único e deduplicado de todos os gêneros cinematográficos.
 - **Colunas:** sk_genre_id BIGINT (PK), nome_genero STRING.
- **gold.dim_people**
 - **Objetivo:** Consolidar todas as pessoas físicas envolvidas na obra.
 - **Colunas:** sk_person_id BIGINT (PK), nome_pessoa STRING, tipo_pessoa STRING (Apenas valores como: 'Ator', 'Diretor', 'Roteirista').
- **gold.dim_companies**
 - **Objetivo:** Catálogo único de produtoras/estúdios.
 - **Colunas:** sk_company_id BIGINT (PK), nome_produtores STRING.
- **gold.dim_reviews**
 - **Objetivo:** Consolidar as avaliações individuais geradas pelos usuários, transformando-as em uma métrica resumida por filme.
 - **Colunas:** sk_review_id BIGINT (PK), sk_movie_id BIGINT (FK para o filme correspondente), qtd_avaliacoes_usuarios INT (Contagem), nota_media_usuarios DOUBLE (Média arredondada em 2 casas decimais).

Como um filme pode ter vários gêneros, vários atores e várias produtoras (e vice-versa), o uso de tabelas-ponte (bridge tables*) é estritamente necessário para conectar a tabela dim_movies às dimensões periféricas sem duplicar o registro da tabela Fato.

- **gold.bridge_movie_genre**
 - **Colunas:** sk_movie_id BIGINT (FK), sk_genre_id BIGINT (FK).

- **gold.bridge_movie_person**
 - **Colunas:** sk_movie_id BIGINT (FK), sk_person_id BIGINT (FK).
- **gold.bridge_movie_company**
 - **Colunas:** sk_movie_id BIGINT (FK), sk_company_id BIGINT (FK).

*se você quiser entender mais sobre bridge tables, visite [Medium](#), [Data Warehouse Info](#), [Kimball group](#)

Entrega 2 — Tabela gold_genai_movies_context

Como segunda entrega da camada Gold, você deve gerar uma tabela de contexto para alimentar o Vector Search do assistente de IA (RAG) do time de Inteligência Artificial.

Estrutura da tabela

Coluna	Descrição
movie_id	Chave natural do filme, para rastreabilidade até as tabelas dimensionais.
title	Título do filme, para referência legível.
llm_context_document	Texto longo (STRING) com o documento consolidado que será vetorizado.

A regra de negócio

A coluna **llm_context_document** deve ser uma concatenação inteligente de dados vindos da Fato e das Dimensões, escrita como frase corrida — não como uma lista de campos separados por vírgula. Template esperado:

"O filme [TÍTULO], lançado no ano de [ANO], faturou [RECEITA] e teve um custo de [ORÇAMENTO]. Estrelado por [ATORES PRINCIPAIS] e dirigido por [DIRETOR], o filme possui a seguinte sinopse: [OVERVIEW]."

Origem dos dados:

- [TÍTULO], [ANO] e [OVERVIEW] → dim_movies.
- [RECEITA] e [ORÇAMENTO] → fact_movies_performance.
- [ATORES PRINCIPAIS] e [DIRETOR] → dim_people + dim_companies via **bridge_movie_person**, filtrando por entity_type. Como há múltiplos atores por filme, será necessário agregá-los em uma única string.

⚠ **Atenção Técnica — a "casca de banana" dos nulos:** funções de concatenação (concat(), operador ||) retornam NULL para a string inteira se qualquer campo envolvido for nulo. Um único campo director ou overview vazio pode fazer o filme inteiro desaparecer da tabela de contexto, silenciosamente. Antes de escrever a concatenação final, avalie no seu notebook: quais campos têm chance real de vir nulos, qual função do Spark/SQL permite um valor de fallback antes da concatenação, e qual texto de fallback faz

sentido para cada campo. O código não será fornecido de propósito — pesquise funções de tratamento de nulo no PySpark/Spark SQL.

3. Orquestração e Otimização

- Crie um **Databricks Workflow (Job)** com no mínimo três tarefas: to_Bronze, to_Silver e to_Gold.
- Configure dependências explícitas: Task_Silver só inicia após a conclusão de Task_Bronze; Task_Gold só inicia após a conclusão de Task_Silver.
- Configure um agendamento (schedule) para o Job, simulando uma rotina real de atualização de dados em produção.

4. Desafio de Analytics

Para validar sua modelagem Gold, resolva as consultas abaixo, as quais abordam perguntas que poderiam ser recorrentes em pautas do dia a dia de um Analista de Dados.

Perguntas de Negócio:

- 1. Qual é a receita total (em R\$) somada de todos os filmes da base?
- 2. Quais são os 5 filmes com maior popularidade? Mostre título e valor de popularidade.
- 3. Quantos filmes cada gênero possui? Liste do maior para o menor volume.
- 4. Para os 10 filmes de maior receita, mostre título, receita (em US\$ e R\$) e a posição de cada um no ranking (RANK()).
- 5. Qual ator teve a maior quantidade de participações nos filmes lançados nos últimos 2 anos*?
- 6. Qual a produtora de filmes teve o maior Lucro nos últimos 5 anos*?

*Para o recorte dos últimos 2 e 5 anos, considere como data limite superior a data de lançamento realizada mais recente na base (ignorando registros com datas futuras ou não lançadas).

5. Formato de Entrega

- Entregar os notebooks com os códigos em formato .ipynb.
 - Landing_to_Bronze
 - Bronze_to_Silver
 - Silver_to_Gold
- Incluir comentários explicativos no código justificando as regras de negócio aplicadas.
- Entregar o arquivo .yaml gerado pela exportação do Job no Databricks.
 - job.yaml
- Entregar uma imagem (print) da execução de sucesso do Job exibindo as dependências entre as tarefas.
- Publicar os arquivos em um repositório GitHub público.

Prazo de Entrega

A atividade deve ser entregue até **segunda-feira, dia 21/09/2026, às 18:00**. Seu código e organização serão avaliados quanto à funcionalidade, usabilidade, aderência aos requisitos estabelecidos e boas práticas de desenvolvimento.